

สมุดบันทึกความคืบหน้าโครงการ

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงการ	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกัณฑ์กร รามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุวิวงศ์
ช่วงเวลา W1	13-19 กรกฎาคม 2569
Repository	github.com/kankawee/thai-dsr
สถานะ	เสร็จสมบูรณ์ — พร้อม commit ขึ้น GitHub แล้ว

1. เป้าหมายของ Week 1

Week 1 มีเป้าหมายหลักคือการวางรากฐานของ pipeline ทั้งหมด ก่อนที่จะเริ่มพัฒนาโมเดลจริงใน Week ถัดไป โดยมี 3 สิ่งที่ต้องพิสูจน์ให้ได้

- ระบบ environment พร้อมใช้งานจริง (library ทุกตัว install ได้)
- โมเดล wav2vec2-large-xlsr-53-th โหลดและ extract embedding ได้จริง
- ผลลัพธ์ embedding มี shape และ dimension ถูกต้อง พร้อมส่งต่อให้ mapper model ใน W3

2. สิ่งที่ทำใน Week 1

2.1 สร้างโครงสร้าง Repository

สร้างโครงสร้างโฟลเดอร์มาตรฐานสำหรับโปรเจกต์ โดยแบ่งแยกชัดเจนตาม responsibility ของแต่ละส่วน

- data/ — เก็บไฟล์เสียง raw, clean, distorted และ embeddings แยกกัน
- src/ — source code แบ่งเป็น preprocessing, models, training, inference, evaluation
- configs/ — hyperparameter และ config แยกออกจากโค้ด
- notebooks/ — สำหรับ explore และ visualize ผลลัพธ์
- results/ — checkpoints, audio samples, logs

เหตุผล: การแบ่งโครงสร้างตั้งแต่แรกทำให้ง่ายต่อการดูแลโค้ดในระยะยาว และสามารถหิบบโค้ดแต่ละส่วนไปอ้างอิงในรายงานได้ง่ายขึ้น

2.2 ตั้งค่า Python Environment

สร้าง virtual environment และติดตั้ง library ทั้งหมดที่จำเป็นสำหรับโปรเจกต์

- transformers (HuggingFace) — โหลดและรัน wav2vec2

- torch + torchaudio — deep learning framework และการจัดการไฟล์เสียง
- librosa — audio processing สำหรับ distortion simulation
- parselmouth — Python wrapper สำหรับ Praat ใช้ทำ formant/F0 perturbation
- speechbrain — สำหรับ speaker embedding (ECAPA-TDNN) ใน Stage B
- pystoi, pesq — ตัวชี้วัดคุณภาพเสียงพูดสำหรับ evaluation

ปัญหาที่เจอ: โปรเจกต์อยู่ใน iCloud Drive ทำให้ไฟล์ .venv กว่า 44,000 ไฟล์กลายเป็น dataless placeholder การ import library ทำให้ระบบต้องโหลดทีละไฟล์จาก iCloud จนค้าง แก้โดยย้ายโปรเจกต์ไปที่ ~/dev/thai-dsr ซึ่งอยู่นอก iCloud sync zone

2.3 สร้าง Audio Recording Script

พัฒนา scripts/record_audio.py สำหรับบันทึกเสียงภาษาไทยจากไมโครโฟนโดยตรง เพื่อสร้าง clean speech dataset เบื้องต้น

- บันทึกที่ sample rate 16,000 Hz (mono) ตามที่ wav2vec2 ต้องการ
- ตั้งชื่อไฟล์อัตโนมัติพร้อม label ของประโยค
- บันทึกเสียงทั้งหมด 10 ประโยค ครอบคลุมสถานการณ์การสื่อสารในชีวิตประจำวัน

เหตุผล: ประโยคที่เลือกสะท้อนสถานการณ์จริงที่ผู้ป่วย Dysarthria ต้องการสื่อสาร เช่น 'ขอน้ำหนึ่งแก้วได้ไหม' 'ช่วยฉันด้วยได้ไหม' 'โทรหาหมอให้ทีได้ไหม' ซึ่งจะใช้เป็น ground truth สำหรับการเทรนโมเดลใน Week ถัดไป

2.4 พัฒนา Embedding Extraction Script

พัฒนา src/preprocessing/extract_embedding.py สำหรับสกัด hidden state จากโมเดล wav2vec2-large-xlsr-53-th

- โหลด pretrained model aioresearch/wav2vec2-large-xlsr-53-th จาก HuggingFace
- รับ .wav file เป็น input พร้อม resample เป็น 16,000 Hz อัตโนมัติ
- จัดการ stereo audio โดย average channels เป็น mono
- extract hidden states จากทุก layer ด้วย output_hidden_states=True
- save แต่ละ layer เป็นไฟล์ .npy แยกกันใน data/embeddings/
- รองรับทั้ง CPU และ CUDA อัตโนมัติ

2.5 Exploration Notebook

สร้าง notebooks/01_explore.ipynb สำหรับ visualize และวิเคราะห์ embedding ที่ได้

- Heatmap เปรียบเทียบ Layer 0 (CNN output), Layer 12 (transformer กลาง), Layer 24 (transformer ท้าย)
- Line chart แสดง mean activation ของแต่ละ layer
- บันทึกการวิเคราะห์เพื่อใช้เป็นข้อมูลตัดสินใจเลือก layer ใน Week 3

3. ผลลัพธ์ที่ได้

3.1 ผลการ Extract Embedding

รัน `extract_embedding.py` กับไฟล์เสียง 10 ไฟล์ใน `data/raw/` สำเร็จทั้งหมด ผลลัพธ์สรุปได้ดังนี้

ตัวชี้วัด	ค่าที่ได้	หมายเหตุ
จำนวน layer	25 layers	Layer 0 = CNN output, Layer 1–24 = Transformer blocks
Hidden dimension	1,024	ตรงกับ wav2vec2-large (base = 768)
Time steps ต่อไฟล์	249 frames	เสียง ~5 วิ @ 16kHz บีบเป็น ~20ms ต่อ frame
Shape ต่อ layer	(249, 1024)	<code>time_steps × hidden_dim</code>
ไฟล์ <code>.numpy</code> ที่บันทึก	250 ไฟล์	10 ไฟล์เสียง × 25 layers
Error	ไม่มี	รันสำเร็จทั้งหมด

3.2 การวิเคราะห์ Layer

จาก `exploration notebook` พบว่า

- Layer 0 (CNN output) มี activation pattern ที่สะท้อน acoustic feature ระดับต่ำ เช่น energy และ spectral shape
- Layer 12 (transformer กลาง) เริ่มเข้ารหัสข้อมูลระดับ phoneme ได้ดีขึ้น
- Layer 24 (transformer ท้าย) activation เอนเอียงไปทาง task-specific (CTC/ASR) มากเกินไป

ข้อสรุปเบื้องต้น: Layer 6–12 น่าจะเหมาะสมที่สุดสำหรับ content representation ในโปรเจกต์นี้ จะทำการทดสอบเปรียบเทียบ layer ใน Week 3 เพื่อตัดสินใจ

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
<code>import torch</code> ค้างไม่ตอบสนอง	<code>.venv</code> อยู่ใน iCloud Drive ทำให้ไฟล์ 44,000+ ไฟล์เป็น dataless placeholder	ย้ายโปรเจกต์ไปที่ <code>~/dev/thai-dsr</code> นอก iCloud zone
<code>torchaudio</code> โหลด <code>.wav</code> ไม่ได้	<code>torchaudio 2.11.0</code> ต้องการ <code>torchcodec</code> ซึ่งไม่ได้อยู่ใน <code>requirements.txt</code>	<code>pip install torchcodec</code> และเพิ่มเข้า <code>requirements.txt</code>

5. สิ่งที่จะทำใน Week 2

- ศึกษา related work กลุ่ม Dysarthric Speech Reconstruction (Unit-DSR, Diff-DSR, RnV, ContentVec)
- เพิ่ม related work เข้าเอกสาร proposal พร้อม citation
- พัฒนา distortion simulation script (src/preprocessing/distortion.py)
 - formant perturbation ด้วย parselmouth
 - tempo perturbation แบบ segment-level ด้วย librosa
 - additive noise ด้วย MUSAN dataset
- สร้าง parallel dataset (clean, distorted) พร้อม manifest.csv
- ตรวจสอบว่าเสียงจำลองฟังดู dysarthric จริงด้วยหู ก่อนเข้าสู่ขั้นตอนเทรน โมเดล

6. Git Commits ของ Week 1

- init: project structure and configs
- feat: add wav2vec2 embedding extractor and audio recorder
- feat: verify wav2vec2-th embedding extraction (25 layers, 1024 dim)
- feat: add embedding exploration notebook