

สมุดบันทึกความคืบหน้าโครงงาน

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงงาน	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกนกศักดิ์ งามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุวิวงศ์
ช่วงเวลา W2	21-27 กรกฎาคม 2569
Repository	github.com/kankawee/thai-dsr
สถานะ	เสร็จสมบูรณ์ — commit ขึ้น GitHub แล้ว

1. เป้าหมายของ Week 2

Week 2 มีเป้าหมายหลัก 2 ด้านที่ต้องดำเนินการควบคู่กัน คือด้าน Literature Review เพื่อสร้างฐานความรู้เรื่อง Dysarthric Speech Reconstruction (DSR) และด้านการพัฒนา distortion simulation pipeline สำหรับสร้าง parallel dataset ที่ใช้เทรนโมเดลใน Week 3-4

- ศึกษา related work กลุ่ม Dysarthric Speech Reconstruction (DSR) อย่างน้อย 3 งาน
- พัฒนา distortion simulation script ที่จำลองลักษณะเสียง dysarthria ได้อย่างสมจริง
- ตรวจสอบความสมจริงด้วยตัวชี้วัดทางอะคูสติกเชิงปริมาณ (jitter, shimmer, HNR)
- สร้าง parallel dataset พร้อม manifest.csv พร้อมส่งต่อให้ Week 3

2. สิ่งที่ทำใน Week 2

2.1 ศึกษา Literature กลุ่ม Dysarthric Speech Reconstruction (DSR)

ค้นพบว่างานวิจัยด้านการแปลงเสียงผู้ป่วย dysarthria ให้เป็นเสียงปกติมีชื่อเรียกเฉพาะในวงการวิจัยว่า Dysarthric Speech Reconstruction (DSR) และยังไม่มียานใดที่ทำกับภาษาไทยเลย ซึ่งเป็น novelty หลักของโปรเจกต์นี้

Paper	ปี	Venue	ความเกี่ยวข้องกับโปรเจก
Unit-DSR	2024	ICASSP	ใช้ HuBERT + discrete speech units + Unit HiFi-GAN vocoder — เป็น baseline หลักที่จะเปรียบเทียบผลด้วย
RnV	2025	ICASSP Workshop	แปลง dysarthric → healthy แบบ unsupervised ด้วย SSL + HiFi-GAN ขึ้นันว่า rhythm/tempo perturbation สำคัญมาก
Diff-DSR	2025	Interspeech	dual-encoder (content + speaker) + diffusion generator — reference architecture ที่ใกล้เคียงโปรเจกนี้มากที่สุด

ข้อสรุปจาก Literature: ทั้ง 3 งานขึ้นันว่า SSL representation (wav2vec2/HuBERT) เป็น standard สำหรับ content extraction และ HiFi-GAN เป็น vocoder ที่ใช้ได้จริงในงาน DSR โดยงานที่ใกล้เคียงที่สุดคือ Diff-DSR ที่ใช้ dual-encoder framework เดียวกับที่โปรเจกนี้วางแผนไว้ แต่ simplify generator เป็น HiFi-GAN แทน diffusion เพื่อให้เทรนได้ภายใน resource ที่มี

2.2 พัฒนา Distortion Simulation Script

พัฒนา src/preprocessing/distortion.py สำหรับจำลองลักษณะเสียงพูดของผู้ป่วย dysarthria โดยใช้ 3 เทคนิคซ้อนกัน ซึ่งแต่ละเทคนิคมีฐานรองรับจากลักษณะ acoustic ของ dysarthric speech จริง

- Formant/Pitch Perturbation (parselmouth/Praat) — เลื่อน formant ratio และใส่ F0 jitter รายเฟรม จำลองการควบคุมสายเสียงที่ไม่เสถียร
- Segment-level Tempo Perturbation (librosa) — ตัดเสียงเป็น segment 0.3-0.5 วินาที แล้ว time-stretch แต่ละ segment ด้วย rate ต่างกัน (0.6x-1.4x ที่ severe) จำลองจังหวะการพูดที่ไม่สม่ำเสมอ ซึ่ง RnV (2025) พิสูจน์ว่าเป็นปัจจัยสำคัญที่สุดในการปรับปรุง intelligibility
- Additive Noise & Reverb (numpy) — เติม Gaussian noise ตาม SNR เป้าหมายและ reverb tail สั้นๆ

แบ่งเป็น 3 ระดับความรุนแรง (mild/moderate/severe) ควบคุมผ่าน SEVERITY_PARAMS ทำให้สามารถสร้าง dataset ที่หลากหลายสำหรับ ablation study ในภายหลัง

2.3 ตรวจสอบความสมจริงด้วยตัวชี้วัดทางอะคูสติก

พัฒนา scripts/measure_acoustics.py สำหรับวัด acoustic features 5 ตัวจากไฟล์เสียงทั้งหมด โดยใช้ parselmouth เพื่อตรวจสอบว่าเสียงจำลองมีลักษณะตรงกับ dysarthric speech จริงตามวรรณกรรม

Feature	Raw (ก่อน)	Severe (หลัง)	เกณฑ์ dysarthric / สถานะ
Jitter (local) %	1.79	4.12 ± 0.91	> 3%  PASS

Shimmer (local) %	7.13	18.89 ± 1.38	> 6%  PASS
HNR dB	15.70	4.78 ± 1.43	< 15 dB  PASS

ที่มาของเกณฑ์อ้างอิง: jitter, shimmer และ HNR เป็น standard acoustic measures ที่ใช้กันในงานวิจัย dysarthric speech (Hernandez et al., APSIPA 2022; Classification of Dysarthria based on the Levels of Severity, arXiv:2310.07264, 2023) และได้รับการยืนยันว่าผู้ป่วย stroke dysarthria มีค่าทั้ง 3 ตัวแตกต่างจากคนปกติอย่างมีนัยสำคัญ (ScienceDirect, 2022; Frontiers in Neuroscience, 2024)

ในรอบแรก jitter ที่ severe ได้แค่ 2.21% ยังไม่ถึงเกณฑ์ 3% จึงปรับ jitter_std จาก 0.025 $\rightarrow$ 0.07 และ re-run ใหม่จนได้ค่าเฉลี่ย 4.12% ผ่านครบทั้ง 3 เกณฑ์

2.4 สร้าง Parallel Dataset และ Manifest

สร้าง data/manifest.csv ผ่าน src/preprocessing/build_manifest.py เป็นไฟล์กลางที่ทุก script ใน Week 3-4 จะอ้างอิง โดยมีคอลัมน์ครบ 7 ตัว ได้แก่ utterance_id, speaker_id, clean_path, distorted_path, severity, transcript และ duration_sec

- 10 utterances $\times$ 3 severity levels = 30 แถว
- รวมเสียง distorted ทั้งหมด 154.4 วินาที
- จับคู่ clean-distorted path อัตโนมัติ พร้อม warning ถ้าไฟล์หาย

3. ผลลัพธ์ที่ได้

- เสียงจำลอง severe ผ่านเกณฑ์ dysarthric speech ครบทั้ง 3 ตัวชี้วัด (jitter 4.12%, shimmer 18.89%, HNR 4.78 dB)
- ได้ parallel dataset 30 คู่ (clean, distorted) พร้อม manifest.csv ที่สมบูรณ์
- ได้ related work 3 งานหลักที่ครอบคลุม state-of-the-art ของ DSR field พร้อม citation
- ค้นพบ literature gap ชัดเจนว่ายังไม่มีงาน DSR ภาษาไทยเลย
- ยืนยัน HiFi-GAN เป็น vocoder ที่ใช้ได้จริงในงาน DSR ทั้งจาก Unit-DSR และ RnV

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
เสียง severe ฟังดู auto tune ไม่เหมือน dysarthria จริง	F0 shift แบบสม่ำเสมอทำให้ฟังดู artificial แทนที่จะเป็น natural instability	ปรับเป็น F0 jitter รายเฟรม + ตรวจสอบด้วย jitter (local) % เซึ่งตัวเลข
Jitter severe อยู่แค่ 2.21% ไม่ถึงเกณฑ์ 3%	jitter_std ใน SEVERITY_PARAMS ตั้งไว้ต่ำเกินไปที่ 0.025	ปรับ jitter_std → 0.07 และ re-run จนได้ 4.12% ผ่านเกณฑ์

5. สิ่งที่จะทำใน Week 3

- เลือก layer ของ wav2vec2 ที่เหมาะสมสำหรับ content representation (ทดสอบ layer 6, 9, 12)
- ออกแบบและพัฒนา mapper model (bi-LSTM หรือ Transformer เล็กๆ)
- เทรน mapper model รอบแรกบน parallel dataset ที่เตรียมไว้
- ตรวจสอบว่า loss ลดลงและ output mel-spectrogram มีรูปร่างใกล้เคียง clean speech

6. Git Commits ของ Week 2

- feat: add distortion simulation script (3 severity levels)
- feat: add acoustic measurement script and validate distortion simulation
- feat: build manifest CSV (30 utterances × 3 severity levels)