

สมุดบันทึกความคืบหน้าโครงงาน

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงงาน	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกัณฑ์วี งามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุริวงศ์
ช่วงเวลา W3	28 กรกฎาคม – 3 สิงหาคม 2569
Repository	github.com/kankawee/thai-dsr
สถานะ	เสร็จสมบูรณ์ — เทรน mapper model ครบ 50 epoch และได้ checkpoint พร้อมใช้

1. เป้าหมายของ Week 3

Week 3 เป็นสัปดาห์สำคัญที่สุดของโปรเจกในขณะนี้ เนื่องจากเป็นครั้งแรกที่ทดสอบว่า mapper model สามารถเรียนรู้การแปลง distorted embedding → clean mel-spectrogram ได้จริงหรือไม่ โดยมีเป้าหมาย 4 ข้อ

- เลือก layer ของ wav2vec2 ที่เหมาะสมที่สุดสำหรับ content representation โดยใช้การวัดเชิงปริมาณ
- พัฒนา DysarthricDataset ที่จัดการ frame rate mismatch ระหว่าง wav2vec2 (~50Hz) และ mel-spectrogram (~86Hz)
- ออกแบบและพัฒนา MapperModel (bi-LSTM) พร้อม Wav2Vec2ContentEncoder
- เทรนโมเดลครบ 50 epoch และได้ checkpoint ที่พร้อมนำไป inference ใน Week 4

2. สิ่งที่ทำใน Week 3

2.1 เลือก Layer ของ wav2vec2 (scripts/select_layer.py)

พัฒนา scripts/select_layer.py เพื่อวัดความเหมาะสมของแต่ละ layer จากทั้ง 25 layers โดยวัด 3 metric บน embedding คู่ (clean, distorted) ของทุก utterance

- Cosine similarity (↑ ดีกว่า) — วัดว่า embedding ของเสียงปกติและเสียงบกพร่องใกล้เคียงกันแค่ไหน layer ที่ cosine สูงแปลว่า content ที่จับได้ทนต่อ distortion
- L2 distance (↓ ดีกว่า) — วัดระยะห่างระหว่าง embedding
- Variance across utterances (↓ ดีกว่า) — วัดความสม่ำเสมอของ layer ข้ามประโยค

ผลที่ได้: Layer 24 มี cosine similarity สูงสุด (0.9740) แต่เกิดจาก LayerNorm ที่ท้าย model บีบ embedding norm จาก ~460 เหลือแค่ ~12 ทำให้ L2 distance ต่ำผิดปกติ (2.64 vs ~70 ของ layer อื่น) ไม่ใช่เพราะ robust จริง ดังนั้นจึงเลือก layer 9 แทน ซึ่งอยู่ในช่วง middle transformer layers ที่งานวิจัยยืนยันว่าเก็บ phonetic content ได้ดีที่สุดโดยไม่ task-specific เกินไป (cosine similarity = 0.926) ผลการวิเคราะห์บันทึกไว้ที่ results/layer_comparison.png

2.2 พัฒนา DysarthricDataset (src/training/dataset.py)

พัฒนา PyTorch Dataset class ที่โหลดข้อมูลจาก manifest.csv และจัดการ frame rate mismatch ซึ่งเป็นจุดเสี่ยงสำคัญของ pipeline

- โหลด distorted embedding จาก .npy (shape T_emb, 1024) และ clean mel-spectrogram จาก .wav (shape T_mel, 80)
- แก้ frame rate mismatch ด้วย linear interpolation: upsample embedding จาก ~50Hz → ~86Hz ให้ T_emb = T_mel
- collate_fn pad sequence ให้ยาวเท่ากันใน batch และ return lengths สำหรับ masked loss

ผลทดสอบ: embedding shape (431, 1024) ตรงกับ mel shape (431, 80) พอดีทุก sample ไม่มี dimension mismatch

2.3 พัฒนา MapperModel และ Wav2Vec2ContentEncoder

พัฒนา src/models/mapper.py และ src/models/encoder.py

Component	รายละเอียด
Input	(batch, T, 1024) — wav2vec2 embedding จาก layer 9
bi-LSTM	2 layers, hidden_size=512, bidirectional=True, dropout=0.1 → output (batch, T, 1024)
LayerNorm	Normalize หลัง LSTM ก่อนเข้า projection
Projection	Linear(1024→256) → ReLU → Linear(256→80)
Output	(batch, T, 80) — predicted mel-spectrogram
Parameters	12,884,304 (12.8 ล้าน)

Wav2Vec2ContentEncoder: encapsulate logic การโหลด airesearch/wav2vec2-large-xlsr-53-th และ extract hidden state layer ที่เลือก โดย freeze น้ำหนักทั้งหมด (freeze=True) ผลทดสอบ: output ตรงกับ embedding ที่ cache ไว้จาก W1 ใดๆ (np.allclose = True)

2.4 เทรน Mapper Model (src/training/train.py)

พัฒนา training script กรอบสมบรูณ์และรันเทรนจริงครบ 50 epoch บน Apple MPS GPU

- Loss: masked L1 loss บน mel-spectrogram (mask padding frames ออกเพื่อไม่ให้รบกวนค่า loss จริง)
- Optimizer: Adam (lr=1e-3), Scheduler: ReduceLROnPlateau (patience=5)
- Data split: 8 train / 2 val, batch_size=4, device=MPS
- Save best checkpoint เมื่อ val loss ดีขึ้น → results/checkpoints/best_mapper.pt (~155MB)

3. ผลลัพธ์ที่ได้

3.1 ผลการเทรน

Epoch	Train Loss	Val Loss	หมายเหตุ
1 / 50	12.4678	12.0055	เริ่มต้น — ยังไม่เรียนรู้
10 / 50	2.7018	2.3819	ลดเร็วมากในช่วงแรก
20 / 50	1.6854	1.6038	train/val ลดพร้อมกัน
30 / 50	1.2452	1.3964	เริ่มเห็น overfit เล็กน้อย
45 / 50	1.0906	1.3192	★ Best checkpoint บันทึก ณ epoch นี้
50 / 50	1.0261	1.3257	val loss สูงกว่า epoch 45 เล็กน้อย

การวิเคราะห์ loss curve: loss ดังจาก 12 เหลือ ~2.5 ใน 10 epoch แรก บ่งชี้ว่าโมเดลเรียนรู้ pattern หลักของ mel-spectrogram ได้รวดเร็ว จากนั้น train และ val ลดพร้อมกันจนถึง epoch 20 หลังจากนั้น train ลดต่อขณะที่ val เริ่มขยับขึ้นเล็กน้อย ซึ่งเป็น overfitting เบาๆ ตามที่คาดไว้เนื่องจาก train set มีเพียง 8 utterances —

ReduceLROnPlateau และ save-best-checkpoint ทำงานตามที่ออกแบบ โดยบันทึก checkpoint ของ epoch 45 แทน epoch 50

3.2 ไฟล์ที่ได้จาก W3

- results/checkpoints/best_mapper.pt (~155MB) — checkpoint พร้อม inference
- results/logs/loss_curve.png — กราฟ train/val loss ทั้ง 50 epoch
- results/layer_comparison.png — กราฟเปรียบเทียบ 25 layers
- src/training/dataset.py, src/training/train.py

- src/models/mapper.py, src/models/encoder.py

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
Layer 24 ถูกแนะนำจาก cosine similarity แต่ไม่เหมาะสมจริง	LayerNorm ทำข model บีบ norm จาก ~460 → ~12 ทำให้ L2 ต่ำผิดปกติ	ใช้ cosine similarity เป็น metric หลัก และพิจารณาว่า layer ทำขสุด task-specific เกินไป เลือก layer 9 แทน
torchaudio.load() ใช้ไม่ได้ใน environment	torchaudio 2.11 ต้องการ torchcodec ที่ไม่ได้ติดตั้ง	เปลี่ยนทุก audio loading เป็น soundfile ซึ่งมีอยู่ใน requirements.txt แล้ว
Frame rate mismatch (wav2vec2 vs mel)	wav2vec2 ~50Hz, mel ~86Hz ทำให้ T ไม่ตรงกัน	Linear interpolation ใน dataset.py upsample embedding → T_mel

5. สิ่งที่จะทำใน Week 4

- พัฒนา inference pipeline (src/inference/run.py): รับ .wav เสียงบกพร่อง → โหลด checkpoint → mapper → HiFi-GAN → output .wav
- ติดตั้งและ fine-tune HiFi-GAN vocoder กับเสียงภาษาไทย
- รัน inference กับ test set ทั้ง 10 utterances และฟังผลด้วยหู
- วัดผลเบื้องต้นด้วย STOI และ PESQ เปรียบเทียบก่อน/หลังผ่านระบบ

6. Git Commits ของ Week 3

- feat: add layer selection script (layer 9-12 recommended)
- feat: add dataset loader with frame rate interpolation
- feat: add mapper model (bi-LSTM) and wav2vec2 content encoder
- feat: train mapper model (best val loss 1.3192 at epoch 45)

สาขาวิศวกรรมปัญญาประดิษฐ์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยสงขลานครินทร์