

สมุดบันทึกความคืบหน้าโครงงาน

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงงาน	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกัณฑ์วี งามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุริวงศ์
ช่วงเวลา W4	4–10 สิงหาคม 2569
Repository	github.com/kankawee/thai-dsr
สถานะ	เสร็จสมบูรณ์ — inference pipeline ครบ end-to-end และได้ baseline evaluation

1. เป้าหมายของ Week 4

Week 4 เป็นสัปดาห์ที่ระบบทุก component มารวมกันครั้งแรกเป็น end-to-end pipeline โดยมีเป้าหมาย 4 ข้อ

- ติดตั้ง HiFi-GAN neural vocoder พร้อม pretrained checkpoint
- พัฒนา inference pipeline ครบสมบูรณ์: distorted .wav $\rightarrow$ clean-sounding .wav
- วัดผลเชิงปริมาณด้วย STOI, PESQ และ SNR เพื่อเป็น baseline
- ทดสอบ cross-lingual experiment (ภาษาอังกฤษ) เพื่อหา bottleneck ของระบบ

2. สิ่งที่ทำใน Week 4

2.1 ติดตั้ง HiFi-GAN Vocoder

Clone HiFi-GAN repository จาก GitHub และดาวน์โหลด pretrained checkpoint 2 ชุดไว้ใน vendor/hifi-gan/checkpoints/

- LJ_FT_T2_V1 (54MB) — fine-tuned บน LJSpeech ภาษาอังกฤษ คุณภาพสูงแต่ domain-specific
- UNIVERSAL_V1 (54MB) — เทรนจาก dataset หลายภาษาและ speaker หลากหลาย robustness สูงกว่า

ทดสอบด้วย dummy mel-spectrogram (1, 80, 100) ผ่าน scripts/test_hifigan.py ได้ output shape (1, 1, 25600)

ถูกต้องตามสูตร $100 \text{ frames} \times 256 \text{ hop size} = 25,600 \text{ samples}$

2.2 พัฒนา Inference Pipeline (src/inference/run.py)

พัฒนา end-to-end inference script ที่รับ distorted .wav เข้าและออกเป็น reconstructed .wav

Step	Component	รายละเอียด
1	Audio loading	โหลด .wav ด้วย soundfile, resample เป็น 16kHz, mono
2	Wav2Vec2Encoder	Extract embedding layer 9 → shape (T_emb, 1024)
3	Interpolation	Upsample embedding → T_mel ด้วย linear interpolation
4	MapperModel	โหลด best_mapper.pt → predicted log-mel (T_mel, 80)
5	Mel clamping	Clamp ค่า mel ให้อยู่ใน [-11, 2] ก่อนเข้า HiFi-GAN
6	HiFi-GAN	UNIVERSAL_V1 แปลง mel → waveform (22050Hz)
7	Output	บันทึก {name}_reconstructed.wav ใน results/audio_samples/

รองรับ --input สำหรับไฟล์เดียว และ --batch สำหรับประมวลผลทุกไฟล์ใน directory อัตโนมัติ รัน batch inference กับ 30 ไฟล์ใน data/distorted/ เฉลี่ย 0.6-0.9 วินาที/ไฟล์ (หลังโหลดโมเดลครั้งแรก)

การแก้ปัญหา mel mismatch: ในรอบแรกใช้ LJ_FT_T2_V1 checkpoint แต่เสียงฟังไม่ออกเนื่องจาก mel normalization ต่างกันระหว่าง mapper (log mel + 1e-9) กับ HiFi-GAN ที่ pretrain บน LJSpeech แก้โดยเปลี่ยนเป็น UNIVERSAL_V1 และเพิ่ม clamp(-11, 2) ทำให้เสียงดีขึ้นเล็กน้อย

2.3 Evaluation Metrics (src/evaluation/metrics.py)

พัฒนา evaluation script วัด 3 ตัวชี้วัดเปรียบเทียบ 2 เงื่อนไข: distorted (input) กับ reconstructed (output ของระบบ) โดยใช้ clean speech เป็น reference

- STOI (Short-Time Objective Intelligibility) — pystoi library วัดความชัดเจนของเสียงพูด
- PESQ (Perceptual Evaluation of Speech Quality) — pesq library จำลองการรับรู้ของมนุษย์
- SNR (Signal-to-Noise Ratio) — numpy implementation วัด signal distortion

เสียงทุกไฟล์ถูก resample เป็น 16kHz และ truncate ให้ความยาวเท่ากันก่อนคำนวณทุก metric

2.4 Cross-lingual Experiment (EN vs TH)

บันทึกเสียงภาษาอังกฤษ 5 utterances เพิ่มเติม รัน pipeline เดิมทั้งหมดกับเสียงภาษาอังกฤษ เพื่อพิสูจน์ว่า bottleneck ของระบบอยู่ที่ไหน

3. ผลลัพธ์ที่ได้

3.1 ผลการประเมิน Baseline (ภาษาไทย, n=10, severity=severe)

Metric	Distorted (mean±std)	Reconstructed (mean±std)	ทิศทาง
STOI	0.1649 ± 0.1557	0.1388 ± 0.0982	↓ -0.026
PESQ	1.1406 ± 0.0520	1.1214 ± 0.0360	↓ -0.019
SNR (dB)	-5.449 ± 0.482	-4.492 ± 0.511	↑ +0.957

การวิเคราะห์: STOI และ PESQ ของ reconstructed ต่ำกว่า distorted เล็กน้อย แต่ SNR ดีขึ้น 0.957 dB แสดงว่าระบบสามารถลด noise component ได้จริง แต่ยังไม่สามารถฟื้นฟู speech intelligibility ได้ สาเหตุหลักมาจาก training data ที่จำกัด (8 utterances) และ vocoder mismatch ระหว่าง mapper output กับ HiFi-GAN ที่ pretrain บน LJSpeech ภาษาอังกฤษ

3.2 ผลการทดสอบ Cross-lingual (TH vs EN)

Metric	TH distorted	TH reconstructed	EN distorted	EN reconstructed
STOI	0.1649	0.1388 ↓	0.1131	0.1243 ↑
PESQ	1.1406	1.1214 ↓	1.0507	1.0259 ↓
SNR (dB)	-5.449	-4.492 ↑	-3.690	-2.267 ↑

ข้อค้นพบสำคัญ: STOI ภาษาอังกฤษดีขึ้นหลังผ่านระบบ (0.1131→0.1243) ในขณะที่ภาษาไทยลดลงเล็กน้อย บ่งชี้ว่า HiFi-GAN ไม่ใช่ bottleneck หลัก เพราะถ้า vocoder เป็นปัญหา ภาษาอังกฤษควรดีกว่าภาษาไทยอย่างเห็นได้ชัด — bottleneck จริงอยู่ที่ mapper model ที่เทรนจาก training data ที่จำกัดเพียง 8 utterances การเพิ่ม dataset จะเป็น improvement หลักที่สำคัญที่สุดใน Week 5

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
เสียง reconstructed ฟังไม่ออก (version แรก)	LJ_FT_T2_V1 checkpoint domain-specific กับ LJSpeech และ mel normalization ต่างกัน	เปลี่ยนเป็น UNIVERSAL_V1 + clamp mel ใน [-11, 2] ก่อนเข้า HiFi-GAN
61 ไฟล์ .wav ถูก track ใน git โดยไม่ตั้งใจ	.gitignore ไม่ได้ exclude results/audio_samples/ ไว้	git rm --cached ไฟล์ทั้งหมด + เพิ่ม results/audio_samples/ ใน .gitignore
.gitignore ไม่ครอบคลุม folder ที่มี suffix _en	Pattern เดิม match แค่ data/raw/ ไม่ match data/raw_en/	เปลี่ยนเป็น wildcard pattern: data/raw*/ และ data/distorted*/

5. สิ่งที่จะทำใน Week 5

- บันทึกเสียงเพิ่มอีก 90 utterances (จาก 10 → 100) และ/หรือ download Thai Common Voice corpus
- Retrain mapper model บน dataset ใหม่และเปรียบเทียบกับ STOI/PESQ กับ baseline นี้
- ทดสอบ fine-tune HiFi-GAN กับเสียงภาษาไทยเพื่อแก้ vocoder mismatch

6. Git Commits ของ Week 4

- feat: setup HiFi-GAN vocoder with pretrained checkpoint
- feat: add end-to-end inference pipeline (30 files reconstructed)
- feat: add evaluation metrics (STOI/PESQ/SNR baseline)
- feat: cross-lingual experiment (EN vs TH evaluation)
- chore: fix gitignore (exclude audio outputs and profraw)