

สมุดบันทึกความคืบหน้าโครงการ

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงการ	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกนกศักดิ์ งามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุวิวงศ์
Repository	github.com/kankawee/thai-dsr
สถานะ	เสร็จบางส่วน — ขยาย dataset และวิเคราะห์ layer เสร็จ ยังไม่ครบทุก layer ในช่วง 6–12

1. เป้าหมายของ Week 5

Week 5 มีเป้าหมายหลัก 2 ข้อ ต่อเนื่องจากการแก้ไข Pre-W5 Critical Fixes (mel spectrogram mismatch, utterance-level split, config sync) เพื่อเตรียมระบบให้พร้อมสำหรับการขยาย dataset และวิเคราะห์ layer อย่างเป็นระบบ

- ขยาย training dataset จาก 10 utterances เดิม ให้ได้อย่างน้อย 100 utterances เพื่อแก้ bottleneck หลักที่พบใน W4 (training data จำกัดเกินไป)
- ทำ Thai-specific layer analysis ในช่วง layer 6–12 ของ wav2vec2 โดยอ้างอิงจากข้อมูลและผลการทดลองภาษาไทยโดยตรง ไม่ใช่ derive จาก literature ภาษาอังกฤษเพียงอย่างเดียว เพื่อยืนยัน/ทบทวนการเลือก layer 9 ที่ใช้อยู่

2. สิ่งที่ทำใน Week 5

2.1 ขยาย Dataset ด้วย Thai Common Voice

- เปลี่ยนแผนจากการอัดเสียงเพิ่มเอง 90 utterances เป็นการดึงข้อมูลจาก Thai Common Voice corpus แทน เพื่อประหยัดเวลาและได้ความหลากหลายของผู้พูดมากกว่า
- รวมเสียงจาก Common Voice 200 utterances เข้ากับเสียงเดิม 10 utterances รวมเป็น 210 utterances
- ใช้เฉพาะ distortion ระดับ severe สำหรับชุดข้อมูลนี้ (ตัดระดับ mild/moderate ออกเพื่อลด scope การทดลอง)
- แบ่ง train/val/test ตาม utterance-level split (ตามวิธีที่แก้ไขไว้ใน Pre-W5 Fixes) ได้ 147/32/31 utterances
- พัฒนา scripts/prepare_common_voice.py สำหรับดาวน์โหลดและเตรียมข้อมูล Common Voice ให้อยู่ในรูปแบบ manifest เดียวกับข้อมูลเดิม

2.2 Layer Analysis (wav2vec2 layer 6, 8, 9, 10, 12)

- ฝึก Bi-LSTM mapper model รอบละ 50 epoch แยกสำหรับแต่ละ layer บน dataset ใหม่ 210 utterances

- พัฒนา scripts/run_layer_analysis.sh สำหรับรัน training อัตโนมัติทีละ layer และ scripts/compare_layers.py สำหรับรวมผลและเปรียบเทียบ
- วัดผลด้วย 4 ตัวชี้วัดบน test set 31 utterances: Val loss, STOI, PESQ, SNR
- layer 6 มีการรันล้มเหลว/เริ่มใหม่หลายครั้งระหว่างทางจากปัญหา dependency และการเชื่อมต่อ Hugging Face แต่ท้ายที่สุดได้ผลครบ

2.3 การตัดสินใจเลือก Layer

- วิเคราะห์ผลทั้ง 4 metric ร่วมกัน พบว่าไม่มี layer ใดเหนือกว่า layer อื่นในทุกตัวชี้วัดพร้อมกัน — layer 8 ดีสุดด้าน val loss/PESQ แต่แย่สุดด้าน SNR, layer 12 ดีสุดด้าน STOI แต่แย่สุดด้าน PESQ
- Layer 9 แม้ไม่ชนะสูงสุดในตัวชี้วัดใดโดยเฉพาะ แต่อยู่ในอันดับ 1-2 ของแทบทุก metric ให้ผลสม่ำเสมอที่สุดในภาพรวม
- ความต่างระหว่าง layer ทั้งหมดอยู่ในช่วงแคบมาก (val loss ต่าง 0.026, STOI ต่าง 0.028) ซึ่งอยู่ในขอบเขตที่ไม่มีความสำคัญทางสถิติเมื่อ test set มีเพียง 31 ตัวอย่าง จึงไม่มีหลักฐานเพียงพอที่จะเปลี่ยนจาก layer 9

3. ผลลัพธ์ที่ได้

3.1 ผลเปรียบเทียบ Layer บน test set (31 utterances)

Layer	Val loss	STOI	PESQ	SNR (dB)
6	1.2936	0.2210	1.0899	-0.5090
8	1.2852	0.2136	1.0979	-0.6434
9 (ใช้อยู่)	1.2885	0.2152	1.0973	-0.5651
10	1.3115	0.1984	1.0930	-0.6427
12	1.3094	0.2265	1.0864	-0.6166

3.2 Cosine Similarity (จากข้อมูลเดิม 10 utterances × 3 severity)

scripts/select_layer.py คำนวณ clean-vs-distorted cosine similarity จากชุดข้อมูลเดิม ไม่ใช่ dataset ใหม่ 210 utterances ของ W5 — ใช้เป็นข้อมูลประกอบเท่านั้น ไม่ใช่หลักฐานชี้ขาด:

Layer 6 = 0.8259, Layer 7 = 0.8631, Layer 8 = 0.8931, Layer 9 = 0.9185, Layer 10 = 0.9293, Layer 11 = 0.9343, Layer 12 = 0.9398

3.3 ข้อเสนอแนะการเลือก Layer

จากการวิเคราะห์ 5 layer (6, 8, 9, 10, 12) บน test set 31 ตัวอย่าง ไม่พบ layer ใดที่เหนือกว่าอย่างมีนัยสำคัญในทุก metric พร้อมกัน Layer 9 แม้ไม่ชนะสูงสุดในตัวชี้วัดใดตัวหนึ่งโดยเฉพาะ แต่ให้ผลสม่ำเสมอในทุกมิติ (val loss, STOI, PESQ, SNR) จึงยังคงเลือกใช้ layer 9 ตามเดิม

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
Layer 6 training ล้มเหลว/เริ่มใหม่หลายครั้ง	ปัญหา dependency และการเชื่อมต่อ Hugging Face ระหว่างรัน	รันซ้ำจนสำเร็จ ได้ผลครบทั้ง 50 epoch
results/layer_analysis_summary.txt ระบุชื่อ โมเดลผิด	เขียนว่า "HuBERT" แต่โมเดลที่ใช้จริงคือ airesearch/wav2vec2-large-xlsr-53-th	แก้ไขเอกสารสรุปให้ตรงกับโมเดลที่ใช้จริง
Common Voice ทุกคลิปมี speaker_id เดียวกัน	ตอนเตรียมข้อมูลไม่ได้ดึง speaker metadata จริงจาก Common Voice	ระบุเป็นข้อจำกัดของ W5 ต้องแก้ก่อนเริ่มงาน ECAPA-TDNN speaker verification ในสัปดาห์ถัดไป

5. สิ่งที่จะทำใน Week 6

- Fine-tune HiFi-GAN vocoder กับเสียงภาษาไทยเพื่อแก้ vocoder mismatch ที่พบตั้งแต่ W4
- ทำ Ablation Study เปรียบเทียบ configuration ต่าง ๆ ของ pipeline
- ดึง speaker_id จริงจาก Common Voice metadata แทน placeholder เดียวกันทั้งหมด
เพื่อเตรียมความพร้อมสำหรับ ECAPA-TDNN speaker verification
- (ถ้ามีเวลา) เพิ่ม layer 7 และ 11 ให้ครบช่วง 6–12 ตามที่ระบุไว้ในแผนเดิม

6. Git Commits ของ Week 5

- feat: add Common Voice dataset preparation script (200 utterances)
- feat: merge Common Voice with existing dataset (210 utterances total)
- feat: add layer analysis pipeline (run_layer_analysis.sh, compare_layers.py)
- feat: train and evaluate mapper models across wav2vec2 layers 6/8/9/10/12
- docs: layer comparison results and W5 summary