

สมุดบันทึกความคืบหน้าโครงการ

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงการ	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกันต์กวี งามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุวิวงศ์
Repository	github.com/kankawee/thai-dsr
สถานะ	เสร็จบางส่วน — แก้ปัญหา vocoder mismatch เสร็จ แต่พบปัญหาความเข้าใจเสียง (intelligibility) ใหม่ที่รุนแรงกว่าเดิม ทดลอง 3 แนวทางแก้ไข Mapper แล้วยังไม่สำเร็จ

1. เป้าหมายของ Week 6

Week 6 เดิมมีแผนต่อเนื่องจาก W5 คือ fine-tune HiFi-GAN vocoder เพื่อแก้ vocoder mismatch และทำ Ablation Study เปรียบเทียบ configuration ต่าง ๆ ของ pipeline อย่างไรก็ตาม ระหว่างการทดสอบเสียงที่ผ่าน pipeline เดิมรูปแบบพบปัญหาความเข้าใจเสียง (intelligibility) ที่รุนแรง — เสียงที่สร้างขึ้นฟังไม่รู้เรื่อง คล้ายสัญญาณรบกวน — จึงปรับลำดับความสำคัญมาแก้ปัญหานี้ก่อน โดยไม่จำกัดกรอบเวลา ตามที่ตกลงกับอาจารย์ที่ปรึกษา

2. สิ่งที่ทำใน Week 6

2.1 Vocoder Fine-tuning และการประเมินผล

- Fine-tune HiFi-GAN vocoder กับข้อมูลเสียงภาษาไทย (Approach A, 10,000 steps) ตามแผนเดิมจาก W5
- ประเมินผลเทียบ baseline (UNIVERSAL_V1) ด้วย STOI/PESQ/SNR จากการ inference จริงบนชุดทดสอบ (ไม่ใช่ค่าจำลอง)
- พบว่า STOI ของ vocoder ที่ fine-tune แล้วต่างจาก baseline เพียง +0.003 ซึ่งไม่มีผลต่อการฟังจริง — เสียงยังคงฟังไม่รู้เรื่องเหมือนเดิม

2.2 การวินิจฉัยสาเหตุ (Diagnostic Chain)

- ทดสอบ Vocoder เดี่ยว: ป้อน mel-spectrogram ที่สะอาด (ground truth) เข้า vocoder ตรง โดยไม่ผ่าน Mapper ได้ STOI 0.94–0.95 และ PESQ 2.65–2.80 → Vocoder ไม่ใช่ตัวปัญหา
- เปรียบเทียบ mel-spectrogram ที่ Mapper ทำนายกับ mel-spectrogram จริง พบว่า Mapper ทำนายค่าแบบเกลี่ยเรียบเกินไป (over-smoothing) — พลังงานเสียงโดยรวมถูกรักษาไว้แต่รายละเอียด formant/harmonic ที่จำเป็นต่อการเข้าใจคำพูดถูกลบไปเกือบทั้งหมด

สรุปได้ว่าจุดบอดของระบบอยู่ที่การทำนาย mel-spectrogram ของ Mapper Model

2.3 ความพยายามแก้ไข Mapper (3 แนวทาง)

- Joint adversarial fine-tuning: เทรน Mapper + Vocoder ร่วมกันแบบ GAN (มี discriminator MPD/MSD) พบ gradient ไม่เสถียรตั้งแต่รอบแรก แก้ด้วย gradient clipping และ GAN warmup schedule แล้วยังไม่ช่วย — ยกเลิกแนวทางนี้
- Postnet (residual mel correction): ต่อ โมดูล Conv1D 5 ชั้นแก้ไข mel ปลายทาง โดย freeze ส่วนอื่นทั้งหมด เทรนด้วย L1 loss เสถียรมาก แต่ STOI ไม่ขึ้นเลยแม้เทรนนานขึ้นและเพิ่ม learning rate
- Weighted layer sum: เทรน Mapper ใหม่จากศูนย์บน embedding ที่ผสมทั้ง 25 layer ของ wav2vec2 ด้วยน้ำหนักที่เรียนรู้ได้ (softmax) STOI ขึ้นชั่วคราวกลางทางแล้วตกกลับ น้ำหนักยังเกือบ uniform ไม่พบ layer ที่โดดเด่นชัดเจน

2.4 การจัดการทรัพยากร

- เปลี่ยนวิธีรัน training process ทุกครั้งให้เป็นแบบ detached (nohup + disown + setsid) เพื่อไม่ให้ process ตายเมื่อ session ของ coding agent หมด usage limit
- ล้างพื้นที่ดิสก์จาก checkpoint/cache ของแนวทางที่ยกเลิกไปแล้ว คืนพื้นที่ประมาณ 4.93 GiB เพื่อเตรียมพื้นที่สำหรับแคช embedding ทั้ง 25 layer

3. ผลลัพธ์ที่ได้

เปรียบเทียบผลของทุกแนวทางบนชุด validation เดียวกัน (8 utterances):

แนวทาง	Val mel L1	STOI	PESQ	หมายเหตุ
Baseline (Mapper layer 9, ยังไม่ปรับแก้)	1.2885	0.2615	1.0944	ค่าอ้างอิงสำหรับการทดลองใน W6 (validation 8 utterances)
Vocoder fine-tuning (Approach A)	—	0.183	—	ต่างจาก baseline เพียง +0.003 ไม่มีผลต่อการฟังจริง เพราะปัญหาไม่ได้อยู่ที่ vocoder
Joint adversarial fine-tuning	ไม่คงที่	ลดลงต่อเนื่อง	—	Gradient ไม่เสถียร แม้แก้ grad-clip + GAN warmup แล้ว — ยกเลิกแนวทางนี้
Postnet (residual mel correction)	ไม่ดีขึ้น	ไม่ดีขึ้น	ไม่ดีขึ้น	เสถียรตลอดการเทรน แต่ final_stoi_improved = false แม้เพิ่ม step และ LR แล้ว

แนวทาง	Val mel L1	STOI	PESQ	หมายเหตุ
Weighted layer sum (25 layers)	1.4501	0.3043	1.0756	STOI สูงสุด 0.3617 ที่ step 200 แล้วลดกลับที่ step 300; PESQ และ mel loss แย่กว่า baseline

ข้อสังเกตสำคัญ: ทั้ง 3 แนวทางแก้ไข Mapper ที่ต่างกันโดยโครงสร้าง (ปรับ Mapper ตรงผ่านการเทรนร่วมกับ Vocoder, แก้ผลลัพธ์ปลายทางด้วย Postnet, เปลี่ยนแหล่งข้อมูล input ของ Mapper) ล้มเหลวในทิศทางเดียวกัน
ชี้ให้เห็นว่าปัญหาอาจไม่ได้อยู่ที่การเลือก layer ของ wav2vec2 เพียงอย่างเดียว แต่อาจเป็นเพราะ wav2vec2 ที่ถูก freeze ไว้ทั้งโมเดล (ไม่ว่าจะเลือกหรือรวม layer แบบใด) ไม่มีรายละเอียดเชิงอะคูสติกที่จำเป็นต่อการสร้างเสียงสะอาดเหลืออยู่
เนื่องจากถูกฝึกมาสำหรับงาน ASR ที่ต้องการ representation ที่ invariant ต่อรายละเอียดเสียงที่ไม่กระทบความหมาย

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
เสียงที่ผ่าน pipeline เต็มรูปแบบฟังไม่รู้เรื่อง คล้ายไม่ชัด	Mapper ทำนาย mel-spectrogram แบบเกลี่ยเรียบเกินไป (over-smoothing) ลบรายละเอียด formant/harmonic ที่จำเป็นต่อการเข้าใจคำพูด	วินิจฉัยด้วย 2 การทดลอง (vocoder-only sanity test, mel comparison) เพื่อยืนยันว่าจุดบอดอยู่ที่ Mapper ไม่ใช่ Vocoder
Joint fine-tuning ของ Mapper+Vocoder ไม่เสถียร (gradient สูงผิดปกติ)	ไม่มี GAN warmup, ไม่มี gradient clipping, loss weight ไม่สมดุล	เพิ่ม grad-clip, GAN warmup schedule, ปรับ loss weight — ยังไม่แก้ปัญหาได้ทั้งหมด จึงยกเลิกแนวทางนี้
Training process ของ local smoke test หยุดกลางทาง	รันแบบ foreground ผูกกับ session ของ coding agent ที่มี usage limit 5 ชั่วโมง	เปลี่ยนมารันแบบ detached (nohup + disown + setsid) ทุกครั้ง ทำให้ process อยู่รอดแม้ session หลัหมดเวลา
พื้นที่ดิสก์ไม่พอสำหรับแคช embedding ทั้ง 25 layer ของ wav2vec2	Checkpoint และ log สะสมจากการทดลองที่ยกเลิกไปแล้ว (joint fine-tuning, Colab bundle)	ลบ checkpoint/cache ที่ไม่ใช้แล้ว คืนพื้นที่ประมาณ 4.93 GiB โดยตรวจยืนยันว่าไฟล์สำคัญยังครบ

5. สิ่งที่จะทำใน Week 7

- เพิ่ม auxiliary spectral input: ป้อน log-mel spectrogram ของเสียงที่มีความผิดปกติ (distorted) เข้า Mapper ควบคู่กับ embedding จาก wav2vec2 โดยไม่แก้ไข wav2vec2
เพื่อทดสอบว่าการให้รายละเอียดอะคูสติกดิบเพิ่มเติมช่วยแก้ปัญหาได้หรือไม่
- หากได้ผลดี: พิจารณาปลด freeze บางส่วนของ wav2vec2 (top layers) เพื่อให้ feature extractor ปรับตัวสำหรับงาน reconstruction โดยเฉพาะ
- หากไม่ได้ผล: ทบทวนโครงสร้างของ Mapper Model เอง
- ยังคงมุ่งแก้ไขปัญหาคำความเข้าใจเสียง (intelligibility) ให้สำเร็จ
ไม่รับแนวทางใช้ผลลัพธ์เสียงที่ดีที่สุดที่มีอยู่แล้วรายงานเป็นข้อจำกัดของระบบ

6. Git Commits ของ Week 6

- feat: add joint adversarial fine-tuning for mapper + vocoder
- fix: add gradient clipping and GAN warmup schedule to joint fine-tuning
- feat: add Postnet residual mel correction module and training script
- feat: add weighted layer sum mapper (25-layer learnable weighting)
- chore: clean up abandoned experiment checkpoints and cache
- docs: W6 vocoder fine-tuning evaluation and intelligibility diagnostics