

สมุดบันทึกความคืบหน้าโครงการ

Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning

ชื่อโครงการ	Speech Re-Synthesis for Speech-Impaired Users Using Self-Supervised Learning
ผู้ดำเนินงาน	นายกันต์กวี งามศรี รหัสนักศึกษา 6610110408
อาจารย์ที่ปรึกษา	ดร.อนันต์ ชกสุริวงศ์
Repository	github.com/KankaweeRamsri/thai-dsr
สถานะ	ทดลองแก้ปัญหาความเข้าใจเสียง (intelligibility) ของ Mapper Model แล้ว 6 แนวทาง ยังไม่พบแนวทางที่แก้ปัญหาได้จริง อยู่ระหว่างวางแผนแนวทางสุดท้ายก่อนนำเสนอจริง

1. เป้าหมายของ Week 7

ต่อเนื่องจาก W6 ที่พบว่า Mapper Model ทำนาย mel-spectrogram แบบเกลี่ยเรียบเกินไป (over-smoothing) และแนวทางแก้ไข 3 วิธีแรก (joint fine-tuning, Postnet, weighted layer sum) ยังไม่สำเร็จ Week 7 มุ่งทดสอบแนวทางเพิ่มเติมอีก 3 แนวทางที่ตั้งอยู่บนสมมติฐานต่างกัน ได้แก่ การเพิ่มข้อมูลอะคูสติกดิบให้ Mapper โดยตรง, การใช้ adversarial loss เฉพาะส่วน mel, และการขยายขนาด dataset สำหรับเทรน Mapper ใหม่ทั้งหมด

2. สิ่งที่ทำใน Week 7

2.1 Auxiliary spectral input (แนวทางที่ 4)

- ป้อน log-mel spectrogram ของเสียงที่มีความผิดปกติ (distorted) เข้า Mapper คู่กับ embedding จาก wav2vec2 โดยไม่แก้ไข wav2vec2 เพื่อทดสอบสมมติฐานว่า wav2vec2 ที่ freeze ไว้ไม่มีรายละเอียดอะคูสติกเหลือพอสำหรับ reconstruction
- ผลลัพธ์แย่กว่า baseline ในเกือบทุกตัวชี้วัด (PESQ ลดลง, mel-L1 แฉ่งจาก 1.2885 เป็น 1.5940) แม้จะมีรายละเอียดอะคูสติกดิบให้ใช้งานเพิ่ม → หักล้างสมมติฐานเรื่อง "ข้อมูลอะคูสติกหายไปจาก wav2vec2" และชี้ว่าปัญหาน่าจะอยู่ที่ความสามารถ/โครงสร้างของ Mapper ในการใช้ข้อมูลมากกว่า

2.2 Mel-only adversarial loss (แนวทางที่ 5)

- เพิ่ม discriminator ขนาดเล็กสำหรับ mel-spectrogram โดยเฉพาะ (แยกจาก joint fine-tuning เดิมที่ขกเลิกไปแล้ว) เริ่มจากน้ำหนัก mapper ที่ converge แล้วจาก baseline พร้อม GAN warmup schedule
- พบบั๊กใน custom gradient-clipping function ทำให้ training ล่มทันที แก้ไขแล้วรันสำเร็จถึง step 300 แบบเสถียร (ไม่มี NaN, clip rate คงที่)

- mel-L1 ดีขึ้นเล็กน้อยจาก baseline (1.2760 vs 1.2885) แต่ STOI/PESQ ยังไม่ดีขึ้น และ GAN loss (discriminator/generator) ยังไม่ converge ที่ step 300 — ยังสรุปไม่ได้ว่าแนวทางนี้ใช้ไม่ได้ แต่ผลระยะสั้นยังไม่ชนะ baseline

2.3 ขยายขนาด dataset (แนวทางที่ 6)

- ขยายข้อมูลฝึกจาก Thai Common Voice จาก 210 เป็น 2,010 clips (เพิ่ม 1,800 clips ใหม่) คง validation/test set เดิมของ W5 ไว้ทั้งหมดเพื่อเปรียบเทียบตรง (train 1,407 / val 302 / test 301)
- ย้ายขั้นตอน embedding extraction และ training ไปรันบน Google Colab (GPU) หลังพบปัญหาพื้นที่ดิสก์ในเครื่องไม่พอ เทรน Mapper ใหม่จากศูนย์ด้วยสถาปัตยกรรมและ recipe เดิม (L1 loss, lr 1e-3) พร้อม early-stop
- Early-stop ที่ epoch 17 (best val loss epoch 11) — เร็วกว่า baseline เดิมที่ overfit ที่ epoch 16 ทั้งที่มีข้อมูลมากกว่า 10 เท่า
- ผลเทียบกับ baseline บนชุด 8 utterances เดิม: STOI แย่ลง (0.2615→0.2501) แต่บนชุด 24 utterances ใหม่ STOI ดีขึ้นชัดเจน (0.2743→0.3169) — สรุปว่าข้อมูลที่มากขึ้นช่วยให้ generalize กับข้อมูลจาก Common Voice ได้ดีขึ้น แต่ไม่ได้แก้ปัญหา over-smoothing โดยรวม

3. ผลลัพธ์ที่ได้ (เทียบทุกแนวทางบน validation set เดิม 8 utterances)

แนวทาง	Val mel L1	STOI	PESQ	หมายเหตุ
Baseline (Mapper layer 9, ยังไม่ปรับแก้)	1.2885	0.2615	1.0944	ค่าอ้างอิงหลักสำหรับการทดลอง (validation 8 utterances เดิมจาก W5)
1. Joint adversarial fine-tuning	ไม่คงที่	ลดลงต่อเนื่อง	—	Gradient ไม่เสถียร แม้แก้ grad-clip + GAN warmup แล้ว — ชกเล็ก
2. Postnet (residual mel correction)	ไม่ดีขึ้น	ไม่ดีขึ้น	ไม่ดีขึ้น	เสถียรตลอดการเทรน แต่ final_stoi_improved = false แม้เพิ่ม step และ LR แล้ว
3. Weighted layer sum (25 layers)	1.4501	0.3043	1.0756	STOI สูงสุด 0.3617 ที่ step 200 แล้วลดลง; น้ำหนักเกือบ uniform ทุก layer
4. Auxiliary spectral input	1.5940	0.2770	แย่ลง	STOI ขยับขึ้นเล็กน้อยแต่ PESQ และ mel-L1 แย่ลงชัดเจน —

แนวทาง	Val mel L1	STOI	PESQ	หมายเหตุ
				หักล้างสมมติฐานว่า wav2vec2 ขาดรายละเอียดอะคูสติก
5. Mel-only adversarial loss	1.2760	0.2584	1.0872	เสถียร (clip rate คงที่ ไม่มี NaN) mel-L1 ดีขึ้นเล็กน้อย แต่ STOI/PESQ ยังไม่ดีขึ้น และ GAN loss ยังไม่ converge ที่ step 300
6. ขยาย dataset (210 → 2,010 clips)	1.3169	0.2501	1.0971	เทรนใหม่จากศูนย์บนข้อมูล 10 เท่า (Google Colab, GPU); STOI บนชุด 8 utterances เดิมแย่ลง แต่ STOI บน 24 utterances ใหม่ดีขึ้น (0.2743→0.3169) — generalize ดีขึ้นแต่ไม่แก้ปัญหาลัก

ข้อสังเกตสำคัญ: ครบ 6 แนวทางที่ทดลองแล้ว ไม่มีแนวทางใดทำให้ STOI บนชุด validation อ้างอิงดีขึ้นอย่างมีนัยสำคัญเทียบ baseline (0.2615) ทั้ง 6 แนวทางครอบคลุมสมมติฐานที่ต่างกันมาก (ปรับ Mapper ตรง, แก้ผลลัพธ์ปลายทาง, เปลี่ยน input feature, เปลี่ยน loss function, เพิ่มขนาดข้อมูล)

แต่ล้มเหลวในทิศทางเดียวกันคือไม่สามารถเรียกรายละเอียดเสียงที่จำเป็นต่อการเข้าใจคำพูดกลับคืนมาได้

สิ่งที่พอเป็นสัญญาณบวก็คือ mel-only adversarial loss (แนวทาง 5) ที่ยังไม่ converge เต็มที่ และการขยาย dataset ที่ช่วยเรื่อง generalization แต่ไม่ใช่ intelligibility โดยตรง

4. ปัญหาที่เจอและวิธีแก้

ปัญหา	สาเหตุ	วิธีแก้
Custom gradient-clipping function ใน mel-adversarial training ทำให้ training ล่มทันที	โค้ด clip() เดิม raise RuntimeError เมื่อ gradient เกินขอบเขต แทนที่จะ rescale ให้อัตโนมัติ	แก้ฟังก์ชันให้ rescale gradient แทนการ โยน error แล้วรันใหม่สำเร็จถึง step 300
พื้นที่ดิสก์เต็ม 100% ซ้ำหลายครั้งระหว่างเตรียมข้อมูลขยาย dataset (ดาวน์โหลด Common Voice + distortion)	ไฟล์เสียงและ embedding cache สะสมจากการดาวน์โหลด/ประมวลผลข้อมูลใหม่ 1,800 คลิป	เปลี่ยนมาดาวน์โหลด Common Voice แบบ streaming (ไม่โหลดทั้ง split 7GB) และเทถึงขยะ (macOS Trash) เป็นระยะเพื่อคืนพื้นที่

ปัญหา	สาเหตุ	วิธีแก้
ขั้นตอนเทรนบนข้อมูลขยาย (embedding extraction + training) ใช้เวลานานและเสียดิสก์เต็มซ้ำถ้ารันในเครื่อง	เครื่องมีพื้นที่ดิสก์จำกัด ไม่มี GPU เฉพาะสำหรับงานนี้	ย้ายขั้นตอน embedding extraction และ training ไปรันบน Google Colab (GPU ฟรี ไม่กระทบดิสก์เครื่อง) แปะข้อมูล+โค้ดเป็น bundle เดียว
การเปรียบเทียบผล (evaluate_expanded_mapper.py) บน Colab ใช้เวลานานกว่าที่คาดและดูเหมือนค้าง	เรียก subprocess โดยไม่ stream output ทำให้ stdout ถูก buffer ไว้ทั้งหมด; script ยังประเมินหลาย variant (fp16/fp32) ต่อ checkpoint	ปรับให้ stream stdout แบบ real-time (PYTHONUNBUFFERED) เพื่อยืนยันว่ากำลังทำงานอยู่จริง ไม่ใช่ค้าง

5. สิ่งที่จะทำใน Week 8 (ก่อนนำเสนอจริง 7 ต.ค.)

- เหลือเวลาจำกัดก่อนวันนำเสนอ จึงเลือกแนวทางเดียวที่มีสัญญาณบวกชัดเจนที่สุดมาต่อยอด: รวม mel-only adversarial loss (แนวทาง 5) เข้ากับ dataset ที่ขยายแล้ว (แนวทาง 6) แล้วเทรนต่อให้ครบ (GAN loss ยังไม่ converge ที่ step 300)
- ตั้งเป้าประเมินผลใหม่บนชุด validation อังอิงเดิม 8 utterances เพื่อเทียบตรงกับทุกแนวทางก่อนหน้านี้
- เตรียมแผนสำรอง: หากยังไม่ได้ผลตามกำหนด จะนำเสนอกระบวนการวินิจฉัยและการทดลองอย่างเป็นระบบ (6-7 แนวทาง, การพิสูจน์/หักล้างสมมติฐานที่ละข้อ) เป็นผลงานหลักของโครงการ พร้อมระบุแนวทางที่มีศักยภาพต่อยอดเป็นงานในอนาคต
- ยังคงมุ่งแก้ไขปัญหาคำความเข้าใจเสียง (intelligibility) ให้สำเร็จจริง ไม่รับแนวทางใช้ผลลัพธ์เสียงที่ดีที่สุดที่มีอยู่แล้วรายงานเป็นข้อจำกัดของระบบโดยไม่พยายามต่อ

6. Git Commits ของ Week 7

- feat: add auxiliary spectral input mapper variant
- feat: add mel-only adversarial discriminator and GAN warmup training
- fix: gradient clipping bug in mel-adversarial training (rescale instead of raise)
- feat: build expanded manifest/splits from Thai Common Voice (210 -> 2,010 clips)
- feat: add early-stop option to training script

- feat: add Colab bundle + notebook for expanded-dataset baseline training
- feat: add `evaluate_expanded_mapper.py` for apples-to-apples comparison
- docs: W7 experiment results and diagnostics